Dokumentasi *Quality Control*

Tahap *quality control* dilakukan untuk menjamin bahwa seluruh berkas audio memenuhi standar kelayakan sebelum dilanjutkan ke proses segmentasi dan anotasi. Pemeriksaan dilakukan pada setiap rekaman menggunakan perangkat lunak Audacity untuk menganalisis audio melalui pengujian dengar langsung.

Terdapat tiga dimensi utama yang diperhatikan dalam melakukan *quality control* sebagai berikut.

1. Format *File* dan Karakteristik Sinyal

   Dilakukan verifikasi apakah seluruh data tersimpan dalam format .wav dan terenkoding linear PCM 16-bit, direkam melalui *mono channel*, serta di-*sampling* menggunakan *sampling rate* sebesar 16 kHz sesuai dengan ketentuan teknis perancangan korpus. Audacity turut memvisualisasikan audio ke dalam bentuk gelombang (*waveform*) sehingga dapat dilakukan pengecekan apakah terjadi *clipping* yang menghilangkan informasi audio atau tidak.

2. Tingkat Kejelasan Audio

   Dilakukan pengecekan apakah tingkat suara yang disampaikan oleh penutur bersifat dominan dan terdengar jernih tanpa tertimbun oleh *noise* dari lingkungan. *Noise* yang dapat mengganggu kualitas suara dapat berupa suara kipas, dengung perangkat elektronik, gema pantulan suara, atau hembusan nafas yang meledak pada mikrofon.

3. Kelengkapan dan Integritas Hasil Rekaman

   Dilakukan pemeriksaan terhadap bagaimana rekaman dimulai dan selesai untuk memastikan kata pertama dan terakhir tidak terpotong, serta memvalidasi penamaan *file* sesuai dengan atribut pada dokumentasi metadata dan anotasi dalam korpus.

Alur pengujian ini ditetapkan untuk memastikan setiap *file* dalam korpus bersifat lengkap dan utuh sehingga aman untuk dinyatakan sebagai status layak pakai.

Penentuan Label Mutu (*Quality Labeling*)

Penilaian kualitas rekaman diklasifikasikan ke dalam tiga tingkatan mutu standar, yaitu *good, acceptable*, dan *reject*, berdasarkan evaluasi yang telah dilakukan. Kriteria yang diterapkan untuk masing-masing label mutu adalah sebagai berikut.

Label Mutu	Kriteria
Good	Audio terdengar secara utuh, tidak terjadi *clipping*,

	artikulasi ujaran dari penutur terdengar jernih dan dapat dibedakan secara definitif, *Signal-to-Noise Ratio* tinggi, dan terbebas dari *noise* yang mengganggu kualitas audio
Acceptable	Terdapat gangguan minor yang tidak merusak kejelasan ucapan penutur, seperti suara helaan napas, tetap tidak menghilangkan informasi yang dimiliki oleh audio.
Reject	*File* mengalami kegagalan fatal seperti *clipping* secara ekstrem, *noise* yang menutupi ucapan penutur, audio terpotong, dan lain sebagainya. Audio dengan label mutu ini perlu segera dilakukan perekaman ulang.

Hasil verifikasi terhadap seluruh berkas audio yang didapatkan dari 10 penutur (5 anggota kelompok beserta 5 narasumber) memberikan distribusi label mutu sebagai berikut.

Label Mutu	Jumlah *File*
Good	148 (98.7%)
Acceptable	2 (1.3%)
Reject	0 (0%)
TOTAL	150 (100%)

Log Permasalahan Kualitas Audio (*Quality Problem Log*)

Seluruh *file* audio hasil perekaman yang dinyatakan dengan label mutu selain *good*, atau dinyatakan memiliki permasalahan teknis, ditabulasikan ke dalam tabel berikut.

Nama *File*	Label Mutu	Deskripsi
S04_T03_001.wav	*Acceptable*	Terdapat *clipping* di beberapa detik awal audio.
S06_T03_001.wav	*Acceptable*	Terdapat *clipping* di beberapa bagian audio.

Untuk kedua *file* audio tersebut, *clipping* hanya mencakup sebagai kecil dari keseluruhan durasi *file*, sedangkan sebagian besar *file* masih menyimpan ujaran penutur dalam kualitas yang baik. Oleh karena itu, *file* tetap dipertahankan dengan label kualitas *acceptable* yang menyatakan bahwa *file* tetap layak untuk ditetapkan dalam korpus.

Evaluasi Kendala Pra-Pemrosesan (*Preprocessing*) dan Hasil Anotasi

Melakukan evaluasi terhadap setiap rekaman dan menyusun anotasi transkripsi menjadi proses yang paling banyak memakan waktu dan membutuhkan ketelitian tinggi dalam pelaksanaan pembentukan korpus ini. Karakteristik ucapan berupa *spontaneous speech* menghadirkan kompleksitas yang jauh lebih tinggi dibandingkan *read speech,* khususnya dalam membentuk anotasi yang menyeluruh dan teliti.

Selain memerlukan banyak waktu, topik percakapan modern sering kali menghasilkan istilah asing atau bahasa di luar bahasa Sunda dalam ucapan oleh penutur, seperti penyebutan merek, istilah / *slang* non-formal, dan lain sebagainya. Oleh karena itu, perlu dilakukan proses tambahan untuk memastikan bahwa penulisan kata-kata serapan konsisten untuk setiap audio sehingga model dapat mengenali setiap *instance* penyebutan leksikal yang sama.

Hasil akhir dari anotasi adalah *file* `metadata.csv` dan `annotation.csv` sebagai berikut.

`metadata.csv`

File	***Speaker***	***Gender***	***Topic***	***Duration***	***Environment***	***Quality***
S04_T01_001.wav	S04	Female	Food	14.6	Indoor	Good

`annotation.csv`

File	***Speaker***	***Start***	***End***	***Topic***	***Transcription***	***Special Event***
S04_T01_001.wav	S04	0.0	4.0	Food	mun keur lapar tapi horéam masak anu ribet atawa bingung hayang dahar naon	-

dengan kolom `Special Event` digunakan untuk menyatakan kondisi-kondisi dalam perekaman yang menurunkan kualitas audio hasil perekaman, seperti *mic clipping*, *noise*, dan lain sebagainya.