Laporan Tugas Besar Fase 1: Pengumpulan Korpus Suara Bahasa Daerah Indonesia

IF4071 Pemrosesan Ucapan



William Andrian Dharma T	13523006
Rafen Max Alessandro	13523031
Karol Yangqian Poetracahya	13523093
Steven Owen Liauw	13523103
Leonard Arif Sutiono	18223120

PROGRAM STUDI TEKNIK INFORMATIKA

SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA

INSTITUT TEKNOLOGI BANDUNG

2026

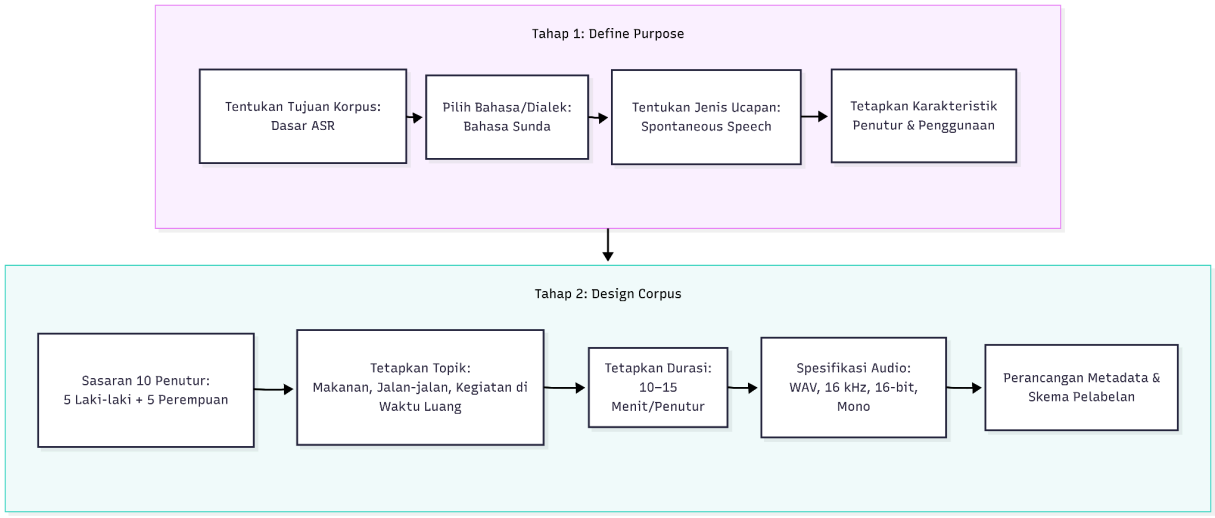
Daftar Isi

Daftar Isi **2**
Pendefinisian Tujuan dan Perancangan Korpus **3**
Ikhtisar Perekaman **4**
I. Demografi Penutur 4
II. Konfigurasi Lingkungan Perekaman 4
Dokumentasi Quality Control **6**
I. Penentuan Label Mutu (Quality Labeling) 6
II. Log Permasalahan Kualitas Audio (Quality Problem Log) 7
III. Evaluasi Kendala Pra-Pemrosesan (Preprocessing) dan Hasil Anotasi 8
Lampiran **9**
I. Link Repositori Github 9
II. Pembagian Tugas 9
III. Daftar Pustaka 9

Pendefinisian Tujuan dan Perancangan Korpus

Sesuai dengan arahan spesifikasi, perancangan korpus pada tugas besar ini ditujukan untuk pemodelan *automated speech recognition* dengan tingkat variabilitas tinggi dan kapabilitas leksikal dalam memahami bahasa daerah alami, yang kelompok sepakati untuk menggunakan bahasa Sunda. Dengan demikian, proses perekaman dilakukan menggunakan *prompt* dengan tiga topik yang telah disepakati, yaitu mengenai makanan, jalan-jalan, dan kegiatan di waktu luang. Ketiga topik dipilih karena kedekatan topik dengan kehidupan sehari-hari sehingga penutur diharapkan mengucapkan kosa kata dengan intonasi spontan yang mencerminkan pemakaian bahasa Sunda percakapan secara otentik.

Proses pengumpulan korpus suara kemudian dirancang dengan hasil rancangan digambarkan oleh bagan berikut.



Rancangan seperti pada gambar dibentuk berdasarkan materi `Pengumpulan Korpus Suara` yang diajarkan di kelas. Pada praktiknya, perancangan proses pengumpulan ini memberikan panduan yang jelas dan terarah dalam melakukan perekaman sehingga proses perekaman dapat dilakukan dengan efektif, efisien, dan memberikan hasil yang optimal.

Ikhtisar Perekaman

I. Demografi Penutur

Speaker ID	Nama	Jenis Kelamin	Asal Daerah
S01	William Andrian Dharma T	L	Surabaya
S02	Nisrina Zakiyah	P	Bandung
S03	Rafen Max Alessandro	L	Bandung
S04	Grace Evelyn Simon	P	Purwokerto
S05	Karol Yangqian Poetracahya	L	Tangerang Selatan
S06	Samantha Benedicta	P	Bandung
S07	Steven Owen Liauw	L	Jakarta
S08	Nadia Apsarani Baizal	P	Bandung
S09	Leonard Arif Sutiono	L	Jakarta
S10	Nakeisha Valya Shakila	P	Tasikmalaya

II. Konfigurasi Lingkungan Perekaman

Lingkungan perekaman dikonfigurasikan secara konsisten dengan spesifikasi konfigurasi sebagai berikut.

Parameter	Spesifikasi / Konfigurasi
Kondisi Ruangan	*Indoor*, relatif tenang
Akustik Ruangan	Minim *echo*
Noise dari Lingkungan	Terkontrol, terbebas dari *noise* berlebih
Jarak Mikrofon	2-4 cm dari *microphone headset*
Format Berkas	WAV
Audio Channel	Mono
Sampling Rate	16 kHz

Bit Depth	16-bit
Recording Level	Rentang puncak -12 dB hingga -6 dB

Dokumentasi *Quality Control*

Tahap *quality control* dilakukan untuk menjamin bahwa seluruh berkas audio memenuhi standar kelayakan sebelum dilanjutkan ke proses segmentasi dan anotasi. Pemeriksaan dilakukan pada setiap rekaman menggunakan perangkat lunak Audacity untuk menganalisis audio melalui pengujian dengar langsung.

Terdapat tiga dimensi utama yang diperhatikan dalam melakukan *quality control* sebagai berikut.

1. Format *File* dan Karakteristik Sinyal

   Dilakukan verifikasi apakah seluruh data tersimpan dalam format .wav dan terenkoding linear PCM 16-bit, direkam melalui *mono channel*, serta di-*sampling* menggunakan *sampling rate* sebesar 16 kHz sesuai dengan ketentuan teknis perancangan korpus. Audacity turut memvisualisasikan audio ke dalam bentuk gelombang (*waveform*) sehingga dapat dilakukan pengecekan apakah terjadi *clipping* yang menghilangkan informasi audio atau tidak.

2. Tingkat Kejelasan Audio

   Dilakukan pengecekan apakah tingkat suara yang disampaikan oleh penutur bersifat dominan dan terdengar jernih tanpa tertimbun oleh *noise* dari lingkungan. *Noise* yang dapat mengganggu kualitas suara dapat berupa suara kipas, dengung perangkat elektronik, gema pantulan suara, atau hembusan nafas yang meledak pada mikrofon.

3. Kelengkapan dan Integritas Hasil Rekaman

   Dilakukan pemeriksaan terhadap bagaimana rekaman dimulai dan selesai untuk memastikan kata pertama dan terakhir tidak terpotong, serta memvalidasi penamaan *file* sesuai dengan atribut pada dokumentasi metadata dan anotasi dalam korpus.

Alur pengujian ini ditetapkan untuk memastikan setiap *file* dalam korpus bersifat lengkap dan utuh sehingga aman untuk dinyatakan sebagai status layak pakai.

I. Penentuan Label Mutu (*Quality Labeling*)

Penilaian kualitas rekaman diklasifikasikan ke dalam tiga tingkatan mutu standar, yaitu *good, acceptable*, dan *reject*, berdasarkan evaluasi yang telah dilakukan. Kriteria yang diterapkan untuk masing-masing label mutu adalah sebagai berikut.

Label Mutu	Kriteria
Good	Audio terdengar secara utuh, tidak terjadi *clipping*,

	artikulasi ujaran dari penutur terdengar jernih dan dapat dibedakan secara definitif, *Signal-to-Noise Ratio* tinggi, dan terbebas dari *noise* yang mengganggu kualitas audio
Acceptable	Terdapat gangguan minor yang tidak merusak kejelasan ucapan penutur, seperti suara helaan napas, tetap tidak menghilangkan informasi yang dimiliki oleh audio.
Reject	*File* mengalami kegagalan fatal seperti *clipping* secara ekstrem, *noise* yang menutupi ucapan penutur, audio terpotong, dan lain sebagainya. Audio dengan label mutu ini perlu segera dilakukan perekaman ulang.

Hasil verifikasi terhadap seluruh berkas audio yang didapatkan dari 10 penutur (5 anggota kelompok beserta 5 narasumber) memberikan distribusi label mutu sebagai berikut.

Label Mutu	Jumlah *File*
Good	148 (98.7%)
Acceptable	2 (1.3%)
Reject	0 (0%)
TOTAL	150 (100%)

II. Log Permasalahan Kualitas Audio (*Quality Problem Log*)

Seluruh *file* audio hasil perekaman yang dinyatakan dengan label mutu selain *good*, atau dinyatakan memiliki permasalahan teknis, ditabulasikan ke dalam tabel berikut.

Nama *File*	Label Mutu	Deskripsi
S04_T03_001.wav	*Acceptable*	Terdapat *clipping* di beberapa detik awal audio.
S06_T03_001.wav	*Acceptable*	Terdapat *clipping* di beberapa bagian audio.

Untuk kedua *file* audio tersebut, *clipping* hanya mencakup sebagai kecil dari keseluruhan durasi *file*, sedangkan sebagian besar *file* masih menyimpan ujaran penutur dalam kualitas yang baik. Oleh karena itu, *file* tetap dipertahankan dengan label kualitas *acceptable* yang menyatakan bahwa *file* tetap layak untuk ditetapkan dalam korpus.

III. Evaluasi Kendala Pra-Pemrosesan (*Preprocessing*) dan Hasil Anotasi

Melakukan evaluasi terhadap setiap rekaman dan menyusun anotasi transkripsi menjadi proses yang paling banyak memakan waktu dan membutuhkan ketelitian tinggi dalam pelaksanaan pembentukan korpus ini. Karakteristik ucapan berupa *spontaneous speech* menghadirkan kompleksitas yang jauh lebih tinggi dibandingkan *read speech,* khususnya dalam membentuk anotasi yang menyeluruh dan teliti.

Selain memerlukan banyak waktu, topik percakapan modern sering kali menghasilkan istilah asing atau bahasa di luar bahasa Sunda dalam ucapan oleh penutur, seperti penyebutan merek, istilah / *slang* non-formal, dan lain sebagainya. Oleh karena itu, perlu dilakukan proses tambahan untuk memastikan bahwa penulisan kata-kata serapan konsisten untuk setiap audio sehingga model dapat mengenali setiap *instance* penyebutan leksikal yang sama.

Hasil akhir dari anotasi adalah *file* `metadata.csv` dan `annotation.csv` sebagai berikut.

`metadata.csv`

File	***Speaker***	***Gender***	***Topic***	***Duration***	***Environment***	***Quality***
S04_T01_001.wav	S04	Female	Food	14.6	Indoor	Good

`annotation.csv`

File	***Speaker***	***Start***	***End***	***Topic***	***Transcription***	***Special Event***
S04_T01_001.wav	S04	0.0	4.0	Food	mun keur lapar tapi horéam masak anu ribet atawa bingung hayang dahar naon	-

dengan kolom `Special Event` digunakan untuk menyatakan kondisi-kondisi dalam perekaman yang menurunkan kualitas audio hasil perekaman, seperti *mic clipping*, *noise*, dan lain sebagainya.

Lampiran

I. Link Repositori Github

Repositori Github hasil pengerjaan tugas besar dapat diakses melalui pranala berikut:
https://github.com/rafenmaxxx/Korpus_Bahasa_Sunda

II. Pembagian Tugas

Nama	NIM	Tugas
William Andrian Dharma T	13523006	Mengatur konfigurasi perekaman secara keseluruhan. Melakukan perekaman S01 dan narasumber S02, beserta dengan anotasi dan metadatanya. QC untuk beberapa audio.
Rafen Max Alessandro	13523031	Melakukan perekaman S03 dan narasumber S04, anotasi dan metadata untuk S03 - S06, membentuk laporan dan dokumentasi QC
Karol Yangqian Poetracahya	13523093	Melakukan perekaman S04 dan narasumber S05
Steven Owen Liauw	13523103	Melakukan perekaman dan anotasi s07 dan s08
Leonard Arif Sutiono	18223120	Melakukan perekaman S09 dan narasumber S10, anotasi dan metadata untuk S08-S10

III. Daftar Pustaka

D. P. Lestari, "Pengumpulan Korpus Suara," Salindia Presentasi Kuliah, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung, Sep. 2026.